

## **Problemática: 7.- Interfaz Cerebro-Computadora para Personas con Discapacidad**

**Equipo: 3A**

**Categoría: 1- NEUROTECH BUILDERS**

**Participantes:**

- Quispe Tancara Aracely Katy
- Suxo Andrade Mauricio Alejandro
- Villarroel Garvizu Milton Alejandro

### **1. Presentación del Problema**

Miles de personas con discapacidad motora severa en Bolivia —especialmente jóvenes entre 15 y 35 años— se encuentran atrapadas en un aislamiento funcional, pese a conservar capacidades cognitivas y visuales plenas. En zonas periurbanas como El Alto, Plan 3000 (Santa Cruz) o la zona sur de Cochabamba, esta condición suele ser consecuencia de accidentes, lesiones medulares o enfermedades neuromusculares (como ELA, atrofia o distrofia muscular).

Aunque estas personas conservan actividades residuales como el movimiento ocular, parpadeos voluntarios, capacidad de soplar, presión muscular localizada o incluso señales cerebrales aprovechables, no existen soluciones accesibles, personalizadas ni escalables que traduzcan esas capacidades en interacción digital.

El uso de interfaces físicas convencionales (mouse, teclado, pantalla táctil) es inviable, lo que los excluye de: educación virtual y técnica, comunicación digital con su entorno, oportunidades laborales remotas, autogestión de su desarrollo personal y profesional.

El uso de herramientas de código abierto, sensores de bajo costo y software personalizable es clave para cerrar la brecha tecnológica y de acceso digital en esta población

El uso de distintas herramientas tecnológicas desde software y hardware a la medida hasta el uso y aplicación de modelos de Machine Learning contribuyen no sólo a las personas en la situación planteada, sino al contexto que las rodea el cuál está conformado por investigadores en accesibilidad, educadores en tecnologías inclusivas, hogares de cuidado y clínicas neurológicas.

Los recursos médicos suelen representar costos elevados, por tal motivo; el uso de herramientas de código abierto tanto en hardware como en software viabilizan el acceso a tecnología de asistencia a bajo costo.

## **2. Propuesta de Solución**

En la búsqueda de una solución de bajo costo, la construcción de una interfaz de control de computadora sin manos, representa una alternativa viable.

La propuesta consta de los siguientes hitos:

- Seguimiento visual con webcam a través de visión artificial: El cursor del mouse sigue la mirada del usuario.
- Interfaz de acción a través de microcontroladores con el uso de la terminal Wio y un sensor barométrico: El usuario ejecuta un “clic” u “acción” a través de la acción de soplar en el sensor para cambiar su lectura.
- Entrenamiento de un modelo de Machine Learning, con base en el dataset, de preferencia etiquetados, para la identificación de acción con reducción de dimensionalidad a dos electrodos.
- Adaptación de la interfaz de acción al uso de SpikerShield de Backyard Brains con dos electrodos y el uso del modelo entrenado.
- Implementación de un archivo ejecutable con la solución propuesta

## **3. Estado del Arte**

### **3.1. Interfaces basadas en seguimiento visual**

Una de las tecnologías más investigadas para usuarios con parálisis severa es el seguimiento visual para controlar el cursor u otros elementos de la interfaz mediante la

mirada. En los últimos años se han desarrollado sistemas de bajo costo usando cámaras web y bibliotecas de visión por computador tal como OpenCV, evitando usar equipos costosos.

Por ejemplo, Paing et al. (2022), donde se implementó un sistema en Raspberry Pi en el que una cámara USB infrarroja captura el movimiento de los ojos del usuario y el software (en C++ con OpenCV) detecta la posición de la pupila y parpadeos utilizando técnicas de procesamiento de imágenes (e.g. transformada de Hough). Logrando así que el movimiento ocular controle el puntero del ratón en la pantalla, mientras que un parpadeo intencional actúa como clic. Estos sistemas pueden permitir navegar por menús, escribir texto (con el uso de teclados virtuales) e incluso manejar una silla de ruedas eléctrica con la mirada.

Además, investigaciones recientes han logrado buena precisión en tiempo real. Karatay et al. (2024) reportan una interfaz basada en ojos con desempeño en tiempo real para controlar aplicaciones en computadora, usando algoritmos optimizados de procesamiento visual y obteniendo comunicación exitosa en personas con tetraplejía. Muchos proyectos de eye-tracking utilizan hardware accesible: La librería OpenCV se ha empleado recurrentemente para localizar pupilas en video, aunque también existen dispositivos comerciales (p.ej. Tobii EyeX, Pupil Labs) con APIs listas para usar.

### ***3.1.1. Fortalezas***

El control por mirada es natural y manos-libres, apropiado incluso para usuarios con síndrome de enclaustramiento. Requiere poco entrenamiento comparado con otras BCI, y permite interacción continua (ej. mover un cursor de forma intuitiva). Los componentes de bajo costo (cámaras estándar, software open source) han demostrado ser viables, haciendo la solución más accesible.

### ***3.1.2. Limitaciones***

La eficacia depende de la capacidad visual y de movimiento ocular del usuario (no es apto para quienes no puedan fijar la mirada). Los sistemas requieren calibración cuidadosa y son sensibles a movimientos de cabeza o cambios de iluminación. Usar

estímulos visuales constantes puede fatigar la vista; sesiones prolongadas con eye-tracking pueden generar cansancio o tensión ocular.

### **3.2. Interfaces con sensores físicos (táctiles, EMG, presión)**

Otra rama del estado del arte se enfoca en sensores físicos y microcontroladores para crear interruptores alternativos que usuarios con movilidad muy reducida puedan accionar. Estos dispositivos aprovechan cualquier movimiento residual o señal física que la persona pueda controlar – por ejemplo, la presión de soplar/aspirar aire, la contracción de un músculo facial, o un leve toque con alguna parte del cuerpo – para generar una señal de entrada.

Un ejemplo clásico son los sistemas de soplo y sorbo (sip-and-puff), usados en sillas de ruedas motorizadas: mediante un tubo, el usuario sopla o aspira para indicar comandos de mover o detenerse. Estos sistemas convierten la presión del aire en señales eléctricas interpretadas por un microcontrolador. Bouyam y Punsawad (2022) extendieron este concepto al diseñar un interfaz de control de silla de ruedas mediante sensores piezoeléctricos colocados en el rostro y la boca, capaces de detectar movimientos sutiles de la lengua o cambios de presión en las mejillas. Su prototipo permitió a personas con tetraplejía severa dirigir una silla de ruedas con movimientos faciales mínimos, demostrando la viabilidad de sensores de presión como alternativa a los joysticks tradicionales (que estos usuarios no pueden manejar).

Otra línea prominente es el uso de señales musculares residuales a través de electromiografía (EMG). Un trabajo de Iqbal et al. (2021) presentó un switch activado por músculo de bajo costo y vestible, empleando sensores MyoWare para recoger la actividad eléctrica de un músculo en la frente o la mejilla. Un sistema que consiste en un Arduino Uno que digitaliza la señal EMG y, cuando detecta una contracción intencionada (superando un umbral), envía un comando vía Bluetooth a la computadora del usuario. En pruebas con esta interfaz, usuarios con parálisis pudieron controlar software de comunicación (p.ej. el programa Grid 3) o dispositivos del hogar, activando funciones de texto a voz, encendido de electrodomésticos, etc., todo con solo tensar un músculo en específico. Este tipo de interruptor EMG aprovecha que algunos pacientes con ELA u otras

condiciones mantienen leves movimientos voluntarios (ej. un pequeño movimiento de ceja o de mandíbula). De modo similar, se han explorado sensores táctiles colocados en la cabeza o en apoyos corporales que reaccionan a un toque o presión leve del usuario (por ejemplo, con la parte posterior de la cabeza).

Álvarez Ariza y Pearce (2022) realizaron una revisión sistemática sobre tecnologías asistivas de bajo costo con hardware/software libre, destacando múltiples proyectos que integran Arduino o placas similares para conectar sensores al ordenador. Hallaron que estas soluciones open-source reducen costos significativamente y permiten personalizar los dispositivos a las necesidades individuales, aunque a veces carecen del pulido comercial o certificaciones clínicas.

En general, la integración sensor-microcontrolador actúa como un puente para traducir acciones no convencionales del usuario (soplar, guiñar, tensar un músculo) en eventos estándar de computadora (clics, teclas) o en señales para controlar sillas de ruedas, brazos robóticos, etc.

### **3.2.1. Fortalezas**

Las interfaces basadas en sensores físicos suelen ser simples, fiables y de bajo costo. Logrando aprovechar movimientos o señales que el usuario ya puede realizar sin entrenamiento (por ejemplo, soplar, cerrar los ojos fuerte, contraer un músculo) para convertirlas en comandos. Son dispositivos que pueden construirse o adaptarse con tecnología accesible (Arduino, sensores comunes). Además, tienden a tener latencia mínima: la acción del usuario se refleja casi inmediatamente en el sistema (más rápido que interpretar señales cerebrales, por ejemplo).

### **3.2.2. Limitaciones**

Por lo general, ofrecen pocos comandos discretos – típicamente uno o dos bits de información (activar/desactivar, clic único). Esto limita la complejidad de las tareas que se pueden realizar únicamente con estos switches; a menudo se usan en combinación con interfaces de exploración (scanning) en pantalla para seleccionar letras o funciones, lo cual puede ser lento. Requieren que el usuario mantenga alguna función motora o fisiológica

residual: si la enfermedad avanza hasta impedir incluso un leve soplo o pestañeo controlado, el sistema deja de ser utilizable.

En el caso de sensores de soplo/aspiración, el usuario debe llevar un tubo cerca de la boca todo el tiempo (posible incomodidad o higiene); con sensores EMG, la colocación de electrodos puede requerir ajuste diario y es susceptible a ruido o fatiga muscular. Comparados con eye-trackers o BCI, estos interfaces no pueden cubrir tareas continuas (como mover un cursor en cualquier dirección), sino más bien comandos discretos que se suelen combinar con software de barrido.

### **3.3. Interfaces cerebro-computadora (BCI) basadas en EEG de pocos electrodos**

Para personas que no pueden mover prácticamente ningún músculo de forma voluntaria, las interfaces cerebro-computadora (Brain-Computer Interfaces, BCI) se vuelven la única vía de control. Estas interfaces interpretan directamente las señales eléctricas del cerebro (electroencefalografía, EEG) para determinar la intención del usuario.

En la última década, los paradigmas de BCI como P300, SSVEP y RSVP han avanzado notablemente, con énfasis en reducir la cantidad de electrodos necesarios y mejorar la facilidad de uso en contextos asistivos.

#### **3.3.1. Paradigma P300**

Se basa en el potencial evocado P300, una onda positiva que aparece unos 300 ms después de un estímulo infrecuente pero relevante (paradigma “oddball”). Siendo el caso más famoso el P300 speller que introducido en 1988 muestra matrices de letras que se iluminan en secuencia; al enfocarse en la letra deseada, cuando ésta se ilumina ocurre un P300 en el EEG.

Los modernos spellers P300 (incluyendo variantes de RSVP – presentación rápida de estímulos uno tras otro) han logrado alrededor de 90% de precisión en promedio con participantes sanos. Por ejemplo, Won et al. (2022) reportan en un amplio conjunto de 55 sujetos ~92% de precisión promedio deletreando con P300, mejorando con repeticiones adicionales de estímulos.

Una ventaja del P300 es que no requiere entrenamiento específico del usuario; incluso personas sin experiencia pueden generar la señal de forma consistente al concentrarse en el estímulo objetivo.

Investigaciones recientes buscan minimizar los electrodos necesarios, ya que un obstáculo práctico es tener que colocar 8, 16 o más sensores en el cuero cabelludo. Por ejemplo, Ogino et al. (2019) demostraron que es posible detectar ERPs auditivos tipo P300 con un solo electrodo prefrontal (usando un dispositivo portátil Emotiv) en combinación con estímulos sonoros (p.ej. cinco tonos naturales distintos). En su estudio, incluso un paciente con ELA pudo seleccionar entre opciones mediante este BCI auditivo de un canal, aunque con menor velocidad que sistemas multi-electrodo convencionales. De igual forma, se han explorado dispositivos de diadema con 1–2 electrodos secos que controlan funciones simples (p.ej. activar un interruptor al detectar un determinado patrón EEG como un P300 o un artefacto de parpadeo voluntario).

### **3.3.2. Paradigma SSVEP**

Las BCI de Steady-State Visual Evoked Potential aprovechan la respuesta cerebral rítmica al mirar un estímulo visual parpadeante. Si en la pantalla se hacen destellar varios iconos a distintas frecuencias, al fijar la vista en uno de ellos el EEG del sujeto muestra un aumento de potencia en la frecuencia correspondiente (y sus armónicos).

Este método permite tener múltiples comandos concurrentes (uno por frecuencia) con alta velocidad de selección – se han logrado interfaces tipo speller con más de 30 símbolos usando SSVEP. Un punto fuerte es su rápida tasa de bits y alta precisión incluso con pocos canales occipitales: algoritmos modernos (basados en análisis en frecuencia y correlación canónica, o más recientemente en redes neuronales convolucionales) pueden detectar la frecuencia objetivo con >90% exactitud utilizando solo 3 canales occipitales.

Se ha comprobado que sistemas SSVEP pueden funcionar con cascos EEG portátiles de pocos electrodos, lo cual es propicio para usuarios en casa. Por ejemplo, Chen et al. (2023) desarrollaron un algoritmo CNN optimizado para EEG de pocos canales, pensando en dispositivos vestibles, logrando identificar correctamente estímulos SSVEP en un prototipo de diadema inalámbrica.

No obstante, SSVEP requiere que el usuario tolere mirar luces parpadeantes constantes, lo que puede ser incómodo o provocar fatiga visual rápidamente. Estudios recientes han tratado de mitigar esto con estímulos menos intensos o usando realidad virtual para integrar los targets de forma más natural, pero sigue siendo un reto de usabilidad.

### **3.3.3. *Paradigma RSVP (Rapid Serial Visual Presentation)***

Esencialmente una variación de P300 donde los estímulos (p.ej. imágenes, palabras o letras) se presentan uno tras otro rápidamente en el mismo lugar. El usuario mentalmente marca el estímulo objetivo cuando aparezca, produciendo un P300. Este enfoque se ha empleado, por ejemplo, para detección de objetos o para deletrear (letras pasando como texto scrolling). Won et al. (2022) combinaron RSVP con deletreo P300 en su dataset y mostraron que los usuarios alcanzaban aproximadamente 92% de aciertos detectando el estímulo objetivo en secuencias rápidas.

En cuanto a investigación reciente, se observan dos tendencias: (1) mejorar la clasificación de señales EEG con menos datos de calibración, y (2) detectar nuevas señales complementarias (como los potenciales de error). Sobre el primer punto, algoritmos de transfer learning y redes profundas han permitido BCIs “plug and play” en cierto grado.

Lee et al. (2020) demostraron un modelo CNN (Convolutional Neural Network) entrenado con muchos datos de otros usuarios que logró un verdadero “zero-training” en línea para un speller P300 – es decir, un nuevo usuario podía usar el sistema sin necesidad de calibración personal previa, con precisión comparable a la obtenida con calibración tradicional. Esto es sumamente relevante para interfaces prácticas, porque tradicionalmente cada usuario debía hacer varios minutos de entrenamiento inicial para que el clasificador “aprendiera” sus señales. La disponibilidad de grandes datasets públicos (como el de Won et al. 2022) ha facilitado este tipo de enfoques generalizados, entrenando redes con decenas de sujetos para lograr robustez inter-sujeto.

En la segunda tendencia, trabajos como el de Bhattacharyya et al. (2017) emplean la detección de ErrP (Error-Related Potential) para mejorar la confiabilidad del BCI: este potencial ocurre cuando el usuario nota que se cometió un error (p. ej., el sistema seleccionó una letra equivocada en el speller).



Bhattacharyya et al. (2017) utilizaron el dataset del BCI Challenge @ NER 2015 (Kaggle) – que contenía EEG de un speller P300 con retroalimentación de errores – y desarrollaron un decodificador capaz de detectar automáticamente esos errores en tiempo real con aproximadamente 80% de precisión, incluso en sujetos nuevos no vistos por el sistema. Emplearon un ensamble de clasificadores lineales sobre un subconjunto optimizado de los 56 canales EEG originales, logrando un desempeño uniformemente alto entre múltiples sujetos y sesiones (F1-score ~83% en validación). Este tipo de solución puede incorporarse para que el BCI corrija o pida repetir automáticamente cuando detecta que la selección fue errónea, haciendo la interfaz más eficiente y segura.

#### **3.3.4. Fortalezas**

Las BCI permiten una comunicación “directa” desde el cerebro, ofreciendo una vía de control incluso a personas en estado de encierro completo (*locked-in*). Los paradigmas como P300 y SSVEP han alcanzado altas precisiones (>90%) en entornos controlados, y las mejoras algorítmicas recientes (redes neuronales, filtros espacio-temporales avanzados) han incrementado la velocidad y confiabilidad.

También es destacable que con tan solo 1–3 electrodos bien ubicados se pueden reconocer comandos simples, lo cual simplifica el montaje en comparación con gorros de 32+ canales. Además, nuevos dispositivos EEG portátiles y secos están haciendo más cómoda la experiencia del usuario (electrodos pre-gelificados o tipo diadema).

A nivel de investigación, la liberación de datasets abiertos y competencias (BBCI, Kaggle, etc.) ha impulsado el campo al permitir comparar métodos sobre datos comunes; por ejemplo, el desafío INRIA BCI 2015 motivó el desarrollo de algoritmos como xDAWN+Riemannian Geometry que luego se adoptaron ampliamente para clasificación de P300.

En síntesis, las BCI ofrecen una alternativa única cuando no hay movimientos utilizables, y continúan mejorando en rapidez, precisión y usabilidad gracias a los avances en procesamiento de EEG y aprendizaje automático.

### **3.3.5. Limitaciones**

La fiabilidad puede verse afectada por ruido, variaciones entre sujetos y cambios en el estado del usuario (fatiga, medicamentos). Muchos sistemas requieren calibración o reducción de datos por usuario, aunque se trabaje en minimizar. También tenemos una tasa de comunicación relativamente baja: un speller P300 típico permite escribir quizás 5–10 caracteres por minuto, mucho más lento que métodos basados en movimiento ocular o de cabeza.

El uso de estímulos externos (flashes visuales, sonidos) puede resultar cansador o molesto tras periodos largos; los usuarios reportan agotamiento con sesiones prolongadas de estimulación rápida. El montaje del equipo EEG no es trivial – aunque se investigan opciones de pocos electrodos, lograr señales de calidad consistente a veces requiere personal capacitado (p.ej., para colocar un gorro EEG húmedo), lo cual dificulta la autonomía. Además, muchos dispositivos EEG portátiles económicos sacrifican calidad de señal, por lo que existe una brecha entre prototipos de laboratorio y productos robustos para el hogar.

Por último, factores como interferencias electromagnéticas, necesidad de recalibrar si se mueve un electrodo, o la variabilidad diaria del EEG (no estacionariedad) siguen siendo desafíos abiertos.

En resumen, las BCI son prometedoras pero complementarias; a menudo se combinan con otras interfaces (ej. usando mirada mientras sea posible, y reservando BCI para cuando aquella falle o para confirmaciones) en un enfoque híbrido.

## **3.4. Datasets abiertos y proyectos destacados (2015–2023)**

El avance en estas tecnologías ha sido impulsado en parte por la disponibilidad de datasets de EEG públicos y competencias que retan a mejorar los algoritmos de clasificación, así como por proyectos académicos que documentan soluciones innovadoras. Dos recursos relevantes de los últimos años son:

### **3.4.1. BCI Challenge @NER 2015 (INRIA-Kaggle)**

Este concurso internacional, organizado por INRIA en 2015, proporcionó un conjunto de datos de EEG de un experimento de P300 speller con retroalimentación de errores (56 canales y múltiples sujetos).

El objetivo era detectar, a partir del EEG, cuándo el sistema había cometido un error al identificar la letra deseada (“A spell on you if you cannot detect errors!” era el lema). Este dataset ha sido usado extensamente como *benchmark*. Por ejemplo, Bhattacharyya et al. (2017) entrenaron su detector de ErrP con datos de 16 sujetos de este conjunto y lo probaron en 10 sujetos nuevos, logrando ~74% de exactitud media en detección de errores en un solo trial.

La solución ganadora de la competencia (publicada por Barachant et al.) combinó filtrado espacial xDAWN con clasificación basada en geometría de Riemann, obteniendo resultados superiores a métodos tradicionales. Esto marcó tendencia en el uso de enfoques de covarianzas EEG y algoritmos de espacio Riemanniano para BCI.

Asimismo, estudios comparativos recientes utilizan estos datos de Kaggle para probar métodos de *deep learning* versus métodos clásicos en detección de P300; por ejemplo, Spüler (2018) evaluó varias arquitecturas CNN en el dataset de Kaggle y en otros, encontrando que con suficientes datos los métodos profundos podían igualar el rendimiento de filtros lineales optimizados.

En suma, el BCI Challenge 2015 brindó un escenario controlado que aceleró el desarrollo de algoritmos generalizables de detección de intenciones y errores en BCI, muchos de los cuales hoy se aplican en sistemas activos reales.

### **3.4.2. EEG RSVP-P300 Speller Dataset (Won et al. 2022)**

Publicado como Scientific Data por investigadores de Corea, este es un extenso dataset abierto que incluye registros EEG de más de 50 participantes en tareas de RSVP y

deletreo P300. Cada participante realizó múltiples sesiones, y se recopilaron también datos de estado en reposo, coordenadas 3D de los electrodos y cuestionarios.

Es valioso por su tamaño; tradicionalmente los estudios BCI tenían 10-20 sujetos, pero este conjunto tiene más de 50, lo que permite aplicar técnicas de deep learning con mayor generalización. De hecho, los autores ya demostraron dos usos: un predictor de desempeño en speller P300 basado en características (Won et al. 2019) y un modelo de zero-training con CNN (Lee et al. 2020) entrenado con este gran volumen de datos. Los resultados base indican 92% de precisión media tanto en detección de objetivo RSVP como en deletreo P300 con paradigmas tradicionales, lo que valida la calidad del dataset.

Este recurso, disponible públicamente en GitHub, se ha consolidado como un benchmark moderno para la evaluación de nuevos algoritmos de clasificación de señales EEG, en especial aquellos orientados al aprendizaje transferido (transfer learning) entre sujetos o paradigmas. Un estudio reciente utilizó el conjunto de datos de Won para entrenar modelos que combinan registros de los paradigmas RSVP y P300, con el objetivo de desarrollar un clasificador unificado de potenciales relacionados a eventos (ERP), independiente de la modalidad de presentación del estímulo. En este trabajo, los autores compararon modelos de aprendizaje profundo con enfoques clásicos como SWLDA, encontrando que un modelo basado en EEG-Inception logró superar a los métodos tradicionales en escenarios intersujeto, lo que demuestra el potencial de estas redes para aplicaciones prácticas sin calibración individual previa (Ravipati, Pouratian, Arnold, & Speier, 2023).

Esta línea de investigación se alinea con la creciente tendencia en la comunidad científica de publicar conjuntos de datos amplios y abiertos —como los provistos en competencias BCI, OpenBCI o BNCI Horizon 2020— que permiten la validación cruzada de enfoques algorítmicos y promueven la generalización en aplicaciones reales de BCI.

La comunidad puede comparar métodos de manera más estricta. En particular, este dataset de Won llena un vacío al proveer muchos sujetos para P300, permitiendo probar técnicas de deep learning sin riesgo de sobreajuste a pocos individuos. Se espera que a futuro surjan más trabajos aprovechándose para optimizar spellers cerebrales en entornos

con zero o few-shot calibration, haciendo las BCI más plug-and-play.

#### 4. Fuentes

1. Álvarez Ariza, J., & Pearce, J. M. (2022). Low-cost assistive technologies for disabled people using open-source hardware and software: A systematic literature review. *IEEE Access*, 10, 124894–124927.  
<https://doi.org/10.1109/ACCESS.2022.3221449>
2. Bhattacharyya, S., Konar, A., Tibarewala, D. N., & Hayashibe, M. (2017). A generic transferable EEG decoder for online detection of error potential in target selection. *Frontiers in Neuroscience*, 11, 226.  
<https://doi.org/10.3389/fnins.2017.00226>
3. Bouyam, C., & Punsawad, Y. (2022). Human–machine interface-based wheelchair control using piezoelectric sensors based on face and tongue movements. *Heliyon*, 8(11), e11679. <https://doi.org/10.1016/j.heliyon.2022.e11679>
4. Fischer-Janzen, A., Wendt, T. M., & Van Laerhoven, K. (2024). A scoping review of gaze and eye tracking-based control methods for assistive robotic arms. *Frontiers in Robotics and AI*, 11, 1326670. <https://doi.org/10.3389/frobt.2024.1326670>
5. Iqbal, A., Kanoga, S., Muto, M., & Mitsukura, Y. (2021). *A wearable low-cost muscle activated switch for wireless control for the physically challenged patients* (Preprint). Research Square. <https://doi.org/10.21203/rs.3.rs-1146360/v1>
6. Lee, J., Won, K., Kwon, M., Jun, S. C., & Ahn, M. (2020). CNN with large data achieves true zero-training in Online P300 brain–computer interface. *IEEE Access*, 8, 74385–74400. <https://doi.org/10.1109/ACCESS.2020.2988057>
7. Paing, M. P., Juhong, A., & Pintavirooj, C. (2022). Design and development of an assistive system based on eye tracking. *Electronics*, 11(4), 535.

<https://doi.org/10.3390/electronics11040535>

8. Ogino, M., Kanoga, S., Muto, M., & Mitsukura, Y. (2019). Analysis of prefrontal single-channel EEG data for portable auditory ERP-based brain–computer interfaces. *Frontiers in Human Neuroscience*, *13*, 250.  
<https://doi.org/10.3389/fnhum.2019.00250>
9. Won, K., Kwon, M., Ahn, M., & Jun, S. C. (2022). EEG dataset for RSVP and P300 speller brain–computer interfaces. *Scientific Data*, *9*(388).  
<https://doi.org/10.1038/s41597-022-01509-w>
10. Ravipati, Y., Pouratian, N., Arnold, C., & Speier, W. (2023). *Evaluating deep learning performance for P300 neural signal classification*. AMIA Annual Symposium Proceedings, 2023, 1474–1483.  
<https://pubmed.ncbi.nlm.nih.gov/38222383/>